PEC2 Análisis de datos ómicos

Esteban Hernández Maldonado

10 de junio de 2020

Contents

1 Resumen	1
2 Objetivos	1 2
3 Materiales y métodos	
3.1 Naturaleza de los datos, tipo de experimiento	2
3.2 Métodos y herramientas utilizadas	2
4 Resultados	2
4.1 Definición de los datos y preprocesado (filtraje y normalización)	2
4.2 Identificación de los genes diferencialmente expresados.	6
4.3 Anotación de resultados	17
4.4 Gene enrichment	19
5 Discusión	19
T is the second of the second	19
6.1 Código R	19

Todo el material de esta práctica está disponible en el repositorio de Github ubicado en https://github.com/ehm2411/Hernandez_Esteban_ADO_PEC2

1 Resumen

Estudio de ultrasecuenciación de 30 muestras de tiroides.

2 Objetivos

Ilustrar el proceso de análisis de datos de ultrasecuenciación mediante la realización de un análisis del tiroides en donde ser comparan tres tipos de infiltración medido en 30 muestras de un total de 292 pertenencientes a 3 grupos: NIT (Not infiltrated tissues) con 236 muestras, SFI (Small focal intiltrates) con 42 muestras y ELI (Extensive lymphoid infiltrates) con 14 muestras.

3 Materiales y métodos

3.1 Naturaleza de los datos, tipo de experimiento

Se dispone de un fichero de puntaje y uno de descripción de las diferentes muestras. Se hace una elección aleatoria de 10 muestras por cada grupo.

3.2 Métodos y herramientas utilizadas

Se ha seguido el workflow habitual del paquete DESeq2 para los estudios de ultrasecuenciación.

Herramientas:

Bioconductor/R

RStudio Markdown paquete DESeq2

4 Resultados

4.1 Definición de los datos y preprocesado (filtraje y normalización)

El fichero de puntajes original tiene información de 292 muestras y 56202 genes. Se ha hecho una selección aleatoria de 10 muestras por cada grupo y se han descartado el resto. Para contruir el objeto dds de clase DESeq2 mediante la función DESeqDataSetFromMatrix se han considerado todas las filas (genes).

Es importante recalcar que se ha tenido especial cuidado en asegurarnos de que los nombres de las filas del fichero coldata coindicen con el nombre de las columnas del fichero de puntaje. De no ser así, la utilización del fichero de tipo DESeq2 daría resultados falsos.

Una vez creado el objeto dds se procede a hacer un filtrado, como vemos a continuación, seleccionando los genes que tienen almenos un puntaje.

```
keep <- rowSums(counts(dds)) > 1
dds <- dds[keep,]</pre>
```

Se ha pasado por tanto de 56202 genes a 43573.

Ahora se tienen que normalizar los datos estabilizando la varianza con la función *vst*. Se descarta el uso de *rlog* debido al gran número de genes que tiene el fichero. Esta normalización hará que métodos exploratorios como el clustering y PCA funcionen mejor.

DataFrame with 30 rows and 5 columns

```
##
                            Experiment SRA_Sample
                                                               Group
                                                                            alias
                                                        sex
##
                              <factor>
                                          <factor> <factor> <factor> <character>
## GTEX.QEL4.0726.SM.3GIJ5
                             SRX222777
                                        SRS389744
                                                       male
                                                                 NIT
                                                                             NIT1
## GTEX.132AR.1126.SM.5P9GA
                                        SRS639146
                             SRX604580
                                                     female
                                                                 NIT
                                                                             NIT2
## GTEX.ZDYS.0626.SM.5J2N5
                             SRX605489
                                        SRS639266
                                                                 NIT
                                                                             NIT3
                                                       male
## GTEX.ZTPG.0826.SM.5DUVC
                             SRX576876 SRS629440
                                                     female
                                                                 NIT
                                                                             NIT4
## GTEX.ZTX8.0626.SM.59HKC
                             SRX625353 SRS646077
                                                       male
                                                                 NIT
                                                                             NIT5
## ...
## GTEX.11XUK.0226.SM.5EQLW
                             SRX619829
                                        SRS644736
                                                     female
                                                                 ELI
                                                                             ELI6
## GTEX.ZYY3.1926.SM.5GZXS
                             SRX568364
                                        SRS627095
                                                     female
                                                                 ELI
                                                                             ELI7
## GTEX.14ABY.0926.SM.5Q5DY
                             SRX575932
                                        SRS629299
                                                       male
                                                                 ELI
                                                                             ELI8
## GTEX.13QJC.0826.SM.5RQKC
                             SRX601511
                                        SRS638114
                                                     female
                                                                 ELI
                                                                             ELI9
## GTEX.YJ89.0726.SM.5P9F7
                             SRX583148
                                        SRS631283
                                                       male
                                                                 ELI
                                                                            ELI10
```

Si visualizamos los datos transformados por la función vst podemos ver un ligera mejora en la dispersión de los genes con puntaje muy bajo, ubicados en la esquina inferior izquierda. No obstante no se consigue una reducción sustancial.


```
library("dplyr")
library("ggplot2")

dds <- estimateSizeFactors(dds)


df <- bind_rows(
    as_data_frame(log2(counts(dds, normalized=TRUE)[, 1:2]+1)) %>%
        mutate(transformation = "log2(x + 1)"),
    as_data_frame(assay(vsd)[, 1:2]) %>% mutate(transformation = "vst"))

colnames(df)[1:2] <- c("x", "y")

ggplot(df, aes(x = x, y = y)) + geom_hex(bins = 80) +
    coord_fixed() + facet_grid( . ~ transformation)</pre>
```




Se calcula ahora las distancias entre muestras para poder crear los Heatmaps.



Y por último se crea el gráfico PCA.

```
plotPCA(vsd, intgroup = c("Group"))
```



4.2 Identificación de los genes diferencialmente expresados.

Aplicamos la función DESeq para detectar los genes diferencialmente expresados y calculamos el conjunto de resultados para cada comparación de dos grupos: NIT-SFI, NIT-ELI y SFI-ELI.


```
dds <- DESeq(dds, parallel =TRUE)</pre>
resNITSFI <- results(dds, contrast=c("Group","NIT","SFI"))</pre>
round_df(as.data.frame(resNITSFI)[1:5,c(1:4,6)],6)
##
                        baseMean log2FoldChange
                                                    lfcSE
                                                                stat
                                                                         padj
## ENSG00000223972.4
                        2.558911
                                      -0.130386 0.722859 -0.180376 0.999856
## ENSG00000227232.4 650.020574
                                       0.205602 0.209761 0.980174 0.992577
## ENSG00000243485.2
                        1.395690
                                      -0.272321 0.683942 -0.398163
                                                                           NA
## ENSG00000237613.2
                        1.545823
                                       0.638594 0.787246 0.811175
                                                                           NA
## ENSG00000268020.2
                        0.877952
                                       0.379479 1.109062 0.342162
                                                                           NA
resNITELI <- results(dds, contrast=c("Group","NIT","ELI"))</pre>
round_df(as.data.frame(resNITELI)[1:5,c(1:4,6)],6)
##
                        baseMean log2FoldChange
                                                    lfcSE
                                                                stat
                                                                         padj
                                       0.307259 0.746107 0.411816 0.837309
## ENSG00000223972.4
                        2.558911
## ENSG00000227232.4 650.020574
                                      -0.026109 0.209767 -0.124466 0.956006
```

```
0.738958 0.761595 0.970276 0.569131
## ENSG00000243485.2
                        1.395690
## ENSG00000237613.2
                        1.545823
                                        2.023002 0.908008 2.227956 0.113529
## ENSG00000268020.2
                        0.877952
                                        0.719051 1.134752 0.633663
resSFIELI <- results(dds, contrast=c("Group", "SFI", "ELI"))</pre>
round_df(as.data.frame(resSFIELI)[1:5,c(1:4,6)],6)
                        baseMean log2FoldChange
                                                    lfcSE
                                                                stat
                                                                          padj
## ENSG00000223972.4
                                        0.437645 0.734491 0.595848 0.775306
                        2.558911
## ENSG00000227232.4 650.020574
                                       -0.231711 0.209758 -1.104659 0.541955
## ENSG00000243485.2
                        1.395690
                                       1.011279 0.736588 1.372923
                                        1.384408 0.929490 1.489428 0.371277
## ENSG00000237613.2
                        1.545823
## ENSG00000268020.2
                                        0.339572 1.151384 0.294925
                        0.877952
table(resNITSFI$padj < 0.05)</pre>
##
## FALSE TRUE
## 28332
            35
table(resNITELI$padj < 0.05)</pre>
##
## FALSE TRUE
## 26007 4894
table(resSFIELI$padj < 0.05)</pre>
##
## FALSE TRUE
## 25762 3450
# genes con un p valor ajustado < 0.1
sum(resNITSFI$padj < 0.1, na.rm=TRUE)</pre>
## [1] 94
sum(resNITELI$padj < 0.1, na.rm=TRUE)</pre>
## [1] 6635
sum(resSFIELI$padj < 0.1, na.rm=TRUE)</pre>
## [1] 4765
resSigNITSFI <- subset(resNITSFI, padj < 0.1)</pre>
resSigNITELI <- subset(resNITELI, padj < 0.1)</pre>
resSigSFIELI <- subset(resSFIELI, padj < 0.1)</pre>
# genes significantes con down-regulation más fuerte
sigNITSFI <- as.data.frame(head(resSigNITSFI[ order(resSigNITSFI$log2FoldChange,</pre>
```

```
decreasing = TRUE), c(1:4,6)]))
sigNITELI <- as.data.frame(head(resSigNITELI[ order(resSigNITELI$log2FoldChange,</pre>
                                                     decreasing = TRUE), c(1:4,6)]))
sigSFIELI <- as.data.frame(head(resSigSFIELI[ order(resSigSFIELI$log2FoldChange,</pre>
                                                     decreasing = TRUE), c(1:4,6)]))
round df(sigNITSFI,6)
##
                       baseMean log2FoldChange
                                                   lfcSE
                                                              stat
                                                                        padj
## ENSG0000143552.5
                       85.61652
                                       3.156954 0.715380 4.412976 0.020659
## ENSG00000261857.2 117.11325
                                       2.624286 0.624706 4.200835 0.037718
## ENSG00000173432.6 155.94748
                                       2.491968 0.618102 4.031648 0.049507
## ENSG00000234617.1 130.72333
                                       0.821907 0.222332 3.696758 0.086035
## ENSG00000128578.5 113.87855
                                      -0.973630 0.255384 -3.812419 0.067093
## ENSG00000029534.15 133.40003
                                      -1.153664 0.318572 -3.621363 0.095025
round_df(sigNITELI,6)
##
                      baseMean log2FoldChange
                                                  lfcSE
                                                            stat
                                                                      padj
## ENSG00000253301.1
                      5.763226
                                      4.875239 1.425621 3.419731 0.007198
## ENSG00000243584.1 4.642794
                                      4.838893 1.027421 4.709749 0.000070
## ENSG00000170419.6 23.096407
                                      4.641573 1.146549 4.048299 0.000938
## ENSG00000236848.2 14.964925
                                      4.157532 1.052434 3.950396 0.001310
## ENSG00000215873.2 1.495046
                                      4.084119 1.114586 3.664248 0.003411
## ENSG00000198414.5 1.256288
                                      3.831388 1.368398 2.799908 0.036279
round_df(sigSFIELI,6)
##
                        baseMean log2FoldChange
                                                    lfcSE
                                                              stat
                                                                        padj
## ENSG00000110680.8 1724.656655
                                        8.177705 1.300593 6.287673 0.000000
## ENSG0000157005.3
                       14.553397
                                        4.701818 1.299887 3.617097 0.005565
                                        4.510044 1.426515 3.161581 0.019456
## ENSG00000253301.1
                        5.763226
## ENSG0000145808.4
                                        4.419819 1.256451 3.517701 0.007369
                        2.268070
## ENSG0000100604.8
                                        4.288142 0.882679 4.858100 0.000059
                       61.927148
## ENSG0000128564.5
                       34.609135
                                        3.919798 0.794097 4.936170 0.000042
Visualizamos los resultados obtenidos.
Count Plot
topGene1 <- rownames(resNITSFI)[which.min(resNITSFI$padj)]</pre>
topGene2 <- rownames(resNITELI)[which.min(resNITELI$padj)]</pre>
topGene3 <- rownames(resSFIELI)[which.min(resSFIELI$padj)]</pre>
library("ggbeeswarm")
library("gridExtra")
geneCounts1 <- plotCounts(dds, gene = topGene1, intgroup = c("Group"),returnData = TRUE)</pre>
```


```
ggplot(geneCounts1, aes(x = Group, y = count, color = Group, group= Group)) +
    scale_y_log10() + geom_point(size = 3) + geom_beeswarm(cex = 2) +
    ggtitle("Count Plot: genes más significantes NIT vs SFI")
```

Count Plot: genes más significantes NIT vs SFI





```
geneCounts2 <- plotCounts(dds, gene = topGene1, intgroup = c("Group"),returnData = TRUE)
ggplot(geneCounts1, aes(x = Group, y = count, color = Group, group= Group)) +
    scale_y_log10() + geom_point(size = 3) + geom_beeswarm(cex = 2) +
    ggtitle("Count Plot: genes más significantes NIT vs ELI")</pre>
```

Count Plot: genes más significantes NIT vs ELI




```
geneCounts3 <- plotCounts(dds, gene = topGene1, intgroup = c("Group"),returnData = TRUE)
ggplot(geneCounts1, aes(x = Group, y = count, color = Group, group= Group)) +
    scale_y_log10() + geom_point(size = 3) + geom_beeswarm(cex = 2) +
    ggtitle("Count Plot: genes más significantes SFI vs ELI")</pre>
```







MA-Plot

```
#resNITSFI <- lfcShrink(dds, coef="Group_NIT_vs_ELI", type="normal")
resNITSFI <- lfcShrink(dds,3,type="normal")
resNITELI <- lfcShrink(dds, coef="Group_NIT_vs_ELI", type="apeglm")
resSFIELI <- lfcShrink(dds, coef="Group_SFI_vs_ELI", type="apeglm")
plotMA(resNITSFI,ylim=c(-5,5),main="MA Plot NIT vs SFI")</pre>
```



plotMA(resNITELI,ylim=c(-5,5),main="MA Plot NIT vs ELI")







Histogramas

```
hist(resNITSFI$pvalue[resNITSFI$baseMean > 1], breaks = 0:20/20,
    col = "grey50", border = "white", main="Histograma p-valores con baseMean > 1 (NIT vs SFI)")
```

Histograma p-valores con baseMean > 1 (NIT vs SFI)




Histograma p-valores con baseMean > 1 (NIT vs ELI)



```
hist(resSFIELI$pvalue[resSFIELI$baseMean > 1], breaks = 0:20/20,
col = "grey50", border = "white", main="Histograma p-valores con baseMean > 1 (SFI vs ELI)")
```


Histograma p-valores con baseMean > 1 (SFI vs ELI)




Gene clustering


```
library("genefilter")
topVarGenes <- head(order(rowVars(assay(vsd)), decreasing = TRUE), 15)

# global
mat <- assay(vsd)[topVarGenes, ]
mat <- mat - rowMeans(mat)
anno <- as.data.frame(colData(vsd)[, c("Group", "alias")])
pheatmap(mat, annotation_col = anno, main="Heat Map 3 NIT-SFI-ELI")</pre>
```






```
# NIT-ELI
matNE <- assay(vsd)[topVarGenes, c(1:10,21:30)]
matNE <- matNE - rowMeans(matNE)
annoNE <- as.data.frame(colData(vsd)[c(1:10,21:30), c("Group","alias")])
pheatmap(matNE, annotation_col = annoNE,main="Heat Map 3 NIT-ELI")</pre>
```



```
# SFI-ELI
matSE <- assay(vsd)[topVarGenes, 11:30]
matSE <- matSE - rowMeans(matSE)
annoSE <- as.data.frame(colData(vsd)[11:30, c("Group","alias")])
pheatmap(matSE, annotation_col = annoSE, main="Heat Map 3 SFI-ELI")</pre>
```



4.3 Anotación de resultados

Se buscan la coincidencias con los genes de la base de datos org.Hs.eg.db. Y los guardamos en el fichero results.csv para una posterior consulta.

```
library("org.Hs.eg.db")
library("AnnotationDbi")
res <- resNITSFI
res$symbol <- mapIds(org.Hs.eg.db,</pre>
```

```
keys=gsub("\\..*", "",row.names(res), fixed = FALSE),
                     column="SYMBOL",
                     keytype="ENSEMBL",
                     multiVals="first")
res$entrez <- mapIds(org.Hs.eg.db,
                     keys=gsub("\\..*", "",row.names(res), fixed = FALSE),
                     column="ENTREZID",
                     keytype="ENSEMBL",
                     multiVals="first")
resOrdered <- res[order(res$pvalue),]
head(resOrdered)
## log2 fold change (MAP): Group SFI vs ELI
## Wald test p-value: Group SFI vs ELI
## DataFrame with 6 rows and 8 columns
##
                              baseMean
                                          log2FoldChange
                                                                      lfcSE
##
                             <numeric>
                                               <numeric>
                                                                  <numeric>
## ENSG00000175857.4 170.051335993014 -3.04565170835467 0.326829434035722
## ENSG00000269404.2 312.440114764659 -3.24064728602351 0.358762704021958
## ENSG00000247982.2 1531.01851888727 -2.6856494106733 0.29549760897354
## ENSG00000167483.13 761.902767558693 -3.08649574105445 0.364988653591468
## ENSG00000068831.14 3445.52660742823 -2.51975741290058 0.286498097469292
## ENSG00000104921.10 305.845849726126 -2.98065706016091 0.370459730549136
##
                                   stat
                                                      pvalue
                                                                              padj
##
                              <numeric>
                                                   <numeric>
                                                                         <numeric>
## ENSG00000175857.4 -9.61956104104329 6.61126905855215e-22 1.25485590265287e-17
## ENSG00000269404.2 -9.59257482306124 8.59137274170118e-22 1.25485590265287e-17
## ENSG00000247982.2 -9.33830034168489 9.78928928783456e-21 9.53215728920744e-17
## ENSG00000167483.13 -9.12921170527036 6.89998725268441e-20 5.03906069063542e-16
## ENSG00000068831.14 -9.02412201966414 1.81142036436817e-19 1.05830423367846e-15
## ENSG00000104921.10 -8.85055163304124 8.70877611503033e-19 4.2400127978711e-15
##
                           symbol
                                       entrez
##
                      <character> <character>
## ENSG0000175857.4
                             GAPT
                                       202309
## ENSG00000269404.2
                             SPIB
                                         6689
                                       283663
## ENSG00000247982.2
                        LINC00926
## ENSG0000167483.13
                           NIBAN3
                                       199786
## ENSG0000068831.14
                          RASGRP2
                                        10235
## ENSG0000104921.10
                                         2208
                            FCER2
```

```
# genes en el top 100
resOrderedDF <- as.data.frame(resOrdered)[1:100, ]
write.csv(resOrderedDF, file = "results.csv")</pre>
```

4.4 Gene enrichment

5 Discusión

Es posible que se tuviera que replantear la selección de 10 muestras de cafda grupo. El grupo NIT qedaria infrarepresentado porque seleccionaríamos aproximadamente un 5% del total miestras que los otros dos grupos estaría sobrerepresentados con un 25% aprox. para el grupo SFI y con un 71% aprox. para el grupo ELI.

6 Apéndice

6.1 Código R

```
#paquetes "nativos" de R
if(!require(magrittr)) install.packages("magrittr", dep=TRUE)
if(!require(dplyr)) install.packages("dplyr", dep=TRUE)
if(!require(ggplot2)) install.packages("ggplot2", dep=TRUE)
if(!require(pheatmap)) install.packages("pheatmap", dep=TRUE)
if(!require(RColorBrewer)) install.packages("RColorBrewer", dep=TRUE)
if(!require(ggbeeswarm)) install.packages("ggbeeswarm", dep=TRUE)
if(!require(edgeR)) install.packages("edgeR", dep=TRUE)
```

```
# paquetes de Bioconductor
if(!require(BiocManager)) install.packages("BiocManager")
if(!require(Rsamtools)) BiocManager::install("Rsamtools")
if(!require(GenomicFeatures)) BiocManager::install("GenomicFeatures")
if(!require(DESeq2)) BiocManager::install("DESeq2")
if(!require(apeglm)) BiocManager::install("apeglm")
if(!require(BiocParallel)) BiocManager::install("BiocParallel")
if(!require(genefilter)) BiocManager::install("genefilter")
if(!require(AnnotationDbi)) BiocManager::install("AnnotationDbi")
if(!require(ReportingTools)) BiocManager::install("ReportingTools")
if(!require(RUVSeq)) BiocManager::install("RUVSeq")
if(!require(sva)) BiocManager::install("sva")
if(!require(Gviz)) BiocManager::install("Gviz")
round_df <- function(x, digits) {</pre>
    # round all numeric variables
    # x: data frame
    # digits: number of digits to round
    numeric_columns <- sapply(x, mode) == 'numeric'</pre>
    x[numeric_columns] <- round(x[numeric_columns], digits)</pre>
    x
# lectura de los ficheros
coldata0 <- read.csv("./input/targets.csv", header=TRUE, sep=",")</pre>
cts0 <- read.csv("./input/counts.csv", header=TRUE, sep=";",row.names = 1)
# comprobación de las dimensiones
dim(coldata0)
dim(cts0)
coldata0$Sample Name <- gsub("[-]",".",coldata0$Sample Name)</pre>
rownames(coldata0) <- coldata0$Sample_Name</pre>
all(rownames(coldata0) %in% colnames(cts0))
all(rownames(coldata0) == colnames(cts0))
# seleccionar aleatóriamente 10 muestras de cada grupo (NIT, SFI y ELI) del fichero "targets"
set.seed(12345)
sample_NIT <- sample(coldata0[which(coldata0$Group=="NIT"), "Sample_Name"],10)</pre>
sample_SFI <- sample(coldata0[which(coldata0$Group=="SFI"), "Sample_Name"],10)</pre>
sample_ELI <- sample(coldata0[which(coldata0$Group=="ELI"), "Sample_Name"],10)</pre>
cts <- cts0[,c(sample_NIT,sample_SFI,sample_ELI)]</pre>
```

```
coldata <- coldata0[c(sample_NIT,sample_SFI,sample_ELI),]</pre>
coldata$alias <- c(paste0("NIT",1:10),paste0("SFI",1:10),paste0("ELI",1:10))</pre>
all(rownames(coldata) %in% colnames(cts))
all(rownames(coldata) == colnames(cts))
library("DESeq2")
dds <- DESeqDataSetFromMatrix(countData = cts,</pre>
                               colData = coldata,
                                design = ~ Group)
nrow(dds)
keep <- rowSums(counts(dds)) > 1
dds <- dds[keep,]
vsd <- vst(dds, blind = FALSE)</pre>
head(assay(vsd)[,1:2], 3) # datos de solo dos muestras
colData(vsd)[,c(1:2,7:8,10)]
library("dplyr")
library("ggplot2")
dds <- estimateSizeFactors(dds)</pre>
df <- bind_rows(</pre>
  as_data_frame(log2(counts(dds, normalized=TRUE)[, 1:2]+1)) %>%
         mutate(transformation = "log2(x + 1)"),
  as_data_frame(assay(vsd)[, 1:2]) %>% mutate(transformation = "vst"))
colnames(df)[1:2] <- c("x", "y")</pre>
ggplot(df, aes(x = x, y = y)) + geom_hex(bins = 80) +
  coord_fixed() + facet_grid( . ~ transformation)
sampleDists <- dist(t(assay(vsd)))</pre>
library("pheatmap")
library("RColorBrewer")
```

```
sampleDistMatrix <- as.matrix( sampleDists )</pre>
rownames(sampleDistMatrix) <- vsd$alias</pre>
colnames(sampleDistMatrix) <- NULL</pre>
colors <- colorRampPalette( rev(brewer.pal(9, "Greens")) )(255)</pre>
pheatmap(sampleDistMatrix,
         clustering_distance_rows = sampleDists,
         clustering_distance_cols = sampleDists,
         col = colors)
plotPCA(vsd, intgroup = c("Group"))
dds <- DESeq(dds, parallel =TRUE)</pre>
resNITSFI <- results(dds, contrast=c("Group","NIT","SFI"))</pre>
round_df(as.data.frame(resNITSFI)[1:5,c(1:4,6)],6)
resNITELI <- results(dds, contrast=c("Group","NIT","ELI"))</pre>
round_df(as.data.frame(resNITELI)[1:5,c(1:4,6)],6)
resSFIELI <- results(dds, contrast=c("Group", "SFI", "ELI"))</pre>
round_df(as.data.frame(resSFIELI)[1:5,c(1:4,6)],6)
table(resNITSFI$padj < 0.05)</pre>
table(resNITELI$padj < 0.05)</pre>
table(resSFIELI$padj < 0.05)</pre>
# genes con un p valor ajustado < 0.1
sum(resNITSFI$padj < 0.1, na.rm=TRUE)</pre>
sum(resNITELI$padj < 0.1, na.rm=TRUE)</pre>
sum(resSFIELI$padj < 0.1, na.rm=TRUE)</pre>
resSigNITSFI <- subset(resNITSFI, padj < 0.1)</pre>
resSigNITELI <- subset(resNITELI, padj < 0.1)</pre>
resSigSFIELI <- subset(resSFIELI, padj < 0.1)</pre>
# genes significantes con down-regulation más fuerte
sigNITSFI <- as.data.frame(head(resSigNITSFI[ order(resSigNITSFI$log2FoldChange,</pre>
                                                        decreasing = TRUE), c(1:4,6)]))
sigNITELI <- as.data.frame(head(resSigNITELI[ order(resSigNITELI$log2FoldChange,</pre>
                                                        decreasing = TRUE), c(1:4,6)]))
sigSFIELI <- as.data.frame(head(resSigSFIELI[ order(resSigSFIELI$log2FoldChange,</pre>
                                                        decreasing = TRUE), c(1:4,6)]))
```

```
round_df(sigNITSFI,6)
round_df(sigNITELI,6)
round_df(sigSFIELI,6)
topGene1 <- rownames(resNITSFI)[which.min(resNITSFI$padj)]</pre>
topGene2 <- rownames(resNITELI)[which.min(resNITELI$padj)]</pre>
topGene3 <- rownames(resSFIELI)[which.min(resSFIELI$padj)]</pre>
library("ggbeeswarm")
library("gridExtra")
geneCounts1 <- plotCounts(dds, gene = topGene1, intgroup = c("Group"),returnData = TRUE)</pre>
ggplot(geneCounts1, aes(x = Group, y = count, color = Group, group= Group)) +
  scale_y_log10() + geom_point(size = 3) + geom_beeswarm(cex = 2) +
  ggtitle("Count Plot: genes más significantes NIT vs SFI")
geneCounts2 <- plotCounts(dds, gene = topGene1, intgroup = c("Group"),returnData = TRUE)</pre>
ggplot(geneCounts1, aes(x = Group, y = count, color = Group, group= Group)) +
  scale_y_log10() + geom_point(size = 3) + geom_beeswarm(cex = 2) +
  ggtitle("Count Plot: genes más significantes NIT vs ELI")
geneCounts3 <- plotCounts(dds, gene = topGene1, intgroup = c("Group"),returnData = TRUE)</pre>
ggplot(geneCounts1, aes(x = Group, y = count, color = Group, group= Group)) +
  scale_y_log10() + geom_point(size = 3) + geom_beeswarm(cex = 2) +
  ggtitle("Count Plot: genes más significantes SFI vs ELI")
library("apeglm")
resultsNames(dds)
#resNITSFI <- lfcShrink(dds, coef="Group_NIT_vs_ELI", type="normal")</pre>
resNITSFI <- lfcShrink(dds,3,type="normal")</pre>
resNITELI <- lfcShrink(dds, coef="Group_NIT_vs_ELI", type="apeglm")
resSFIELI <- lfcShrink(dds, coef="Group SFI vs ELI", type="apeglm")
plotMA(resNITSFI,ylim=c(-5,5),main="MA Plot NIT vs SFI")
plotMA(resNITELI, ylim=c(-5,5), main="MA Plot NIT vs ELI")
plotMA(resSFIELI,ylim=c(-5,5),main="MA Plot SFI vs ELI")
hist(resNITSFI$pvalue[resNITSFI$baseMean > 1], breaks = 0:20/20,
     col = "grey50", border = "white",main="Histograma p-valores con baseMean > 1 (NIT vs SFI)")
hist(resNITELI$pvalue[resNITELI$baseMean > 1], breaks = 0:20/20,
     col = "grey50", border = "white",main="Histograma p-valores con baseMean > 1 (NIT vs ELI)")
```

```
hist(resSFIELI$pvalue[resSFIELI$baseMean > 1], breaks = 0:20/20,
     col = "grey50", border = "white", main="Histograma p-valores con baseMean > 1 (SFI vs ELI)")
library("genefilter")
topVarGenes <- head(order(rowVars(assay(vsd)), decreasing = TRUE), 15)</pre>
# global
mat <- assay(vsd)[topVarGenes, ]</pre>
mat <- mat - rowMeans(mat)</pre>
anno <- as.data.frame(colData(vsd)[, c("Group", "alias")])</pre>
pheatmap(mat, annotation_col = anno,main="Heat Map 3 NIT-SFI-ELI")
# NIT-SFI
matNS <- assay(vsd)[topVarGenes, 1:20]
matNS <- matNS - rowMeans(matNS)</pre>
annoNS <- as.data.frame(colData(vsd)[1:20, c("Group", "alias")])</pre>
pheatmap(matNS, annotation_col = annoNS, main="Heat Map 3 NIT-SFI")
# NIT-ELI
matNE <- assay(vsd)[topVarGenes, c(1:10,21:30)]</pre>
matNE <- matNE - rowMeans(matNE)</pre>
annoNE <- as.data.frame(colData(vsd)[c(1:10,21:30), c("Group", "alias")])
pheatmap(matNE, annotation_col = annoNE, main="Heat Map 3 NIT-ELI")
matSE <- assay(vsd)[topVarGenes, 11:30]</pre>
matSE <- matSE - rowMeans(matSE)</pre>
annoSE <- as.data.frame(colData(vsd)[11:30, c("Group", "alias")])</pre>
pheatmap(matSE, annotation_col = annoSE, main="Heat Map 3 SFI-ELI")
library("org.Hs.eg.db")
library("AnnotationDbi")
res$symbol <- mapIds(org.Hs.eg.db,
                      keys=gsub("\\..*", "",row.names(res), fixed = FALSE),
                      column="SYMBOL",
                      keytype="ENSEMBL",
                      multiVals="first")
res$entrez <- mapIds(org.Hs.eg.db,
                      keys=gsub("\\..*", "",row.names(res), fixed = FALSE),
                      column="ENTREZID",
                      keytype="ENSEMBL",
                      multiVals="first")
```

```
resOrdered <- res[order(res$pvalue),]
head(resOrdered)

# genes en el top 100
resOrderedDF <- as.data.frame(resOrdered)[1:100, ]
write.csv(resOrderedDF, file = "results.csv")</pre>
```